



# **10<sup>th</sup> International Conference on Science and Engineering 2019**

Yangon Technological University (YTU), Myanmar

## **Rule-based Myanmar Language Chatbot for Travel and Tourism Domain**

8.12.2019 (Sunday)

Htet Htet Yadanar Oo<sup>1</sup>, May Thae Sue<sup>2</sup>, Ye Kyaw Thu<sup>3,4</sup>, Hnin Aye Thant<sup>1</sup>, Nang Aye Aye Htwe<sup>2</sup>

<sup>1</sup>University of Technology (Yatanarpon Cyber City), Myanmar

<sup>2</sup>Mandalay Technological University, Myanmar

<sup>3</sup>National Electronics and Computer Technology Center (NECTEC), Thailand

<sup>4</sup>Language Understanding Lab., Myanmar

# Outlines

- Introduction
- Aim and Objectives
- Data Preparation and Collection
- Regular Expression (RE)
- Word Segmentation
- POS Tagging
- String Similarity
- System Design
- System Implementation
- Evaluation
- Features and Limitations
- Future Extensions

# Introduction

- Chatbot is a computer program that can communicate with human through natural language via text or voice input.
- Artificial Intelligence (AI) or Natural Language Processing (NLP) is usually embedded in a chatbot to understand the context and perform much more complicated tasks than what a bot does
- Travel and tourism chatbot is a human-computer dialog system that operates through natural language via text.
- This proposed system is a virtual assistant programmed to automatically answer user requests and can perform as a travel adviser for local travelers
- It can provide 24-7 customer services and support.

# Aim and Objectives

## **Aim**

- To help the users who want to travel around Myanmar

## **Objectives**

- To provide transportation advices for the users
- To give suggestion and recommendation places for travellers
- To suggest suitable moments for the trip
- To make local people easy and comfortable for their trip

# Data Preparation and Collection

- Prepare and collect parallel Myanmar sentences (Questions and Answers).
- Collect **7394** parallel Myanmar sentences for Mon State, Kachin State, Shan State, Mandalay and Pyin Oo Lwin regions

For example:

Q - မွန် ပြည်နယ် မှာ အထင်ကရ နေရာ တွေ က ဘယ် နေရာ တွေ လဲ ။

A - မွန် ပြည်နယ် မှာ အထင်ကရ နေရာ တွေ က ကျိုက်ထီးရိုး ဘုရား ၊ ကျိုက္ခမီ ရေလယ် ဘုရား တို့ ဖြစ်  
တယ် ။

Q - မန္တလေး မှာ ဘာ ဘုရား တွေ ရှိ လဲ ။

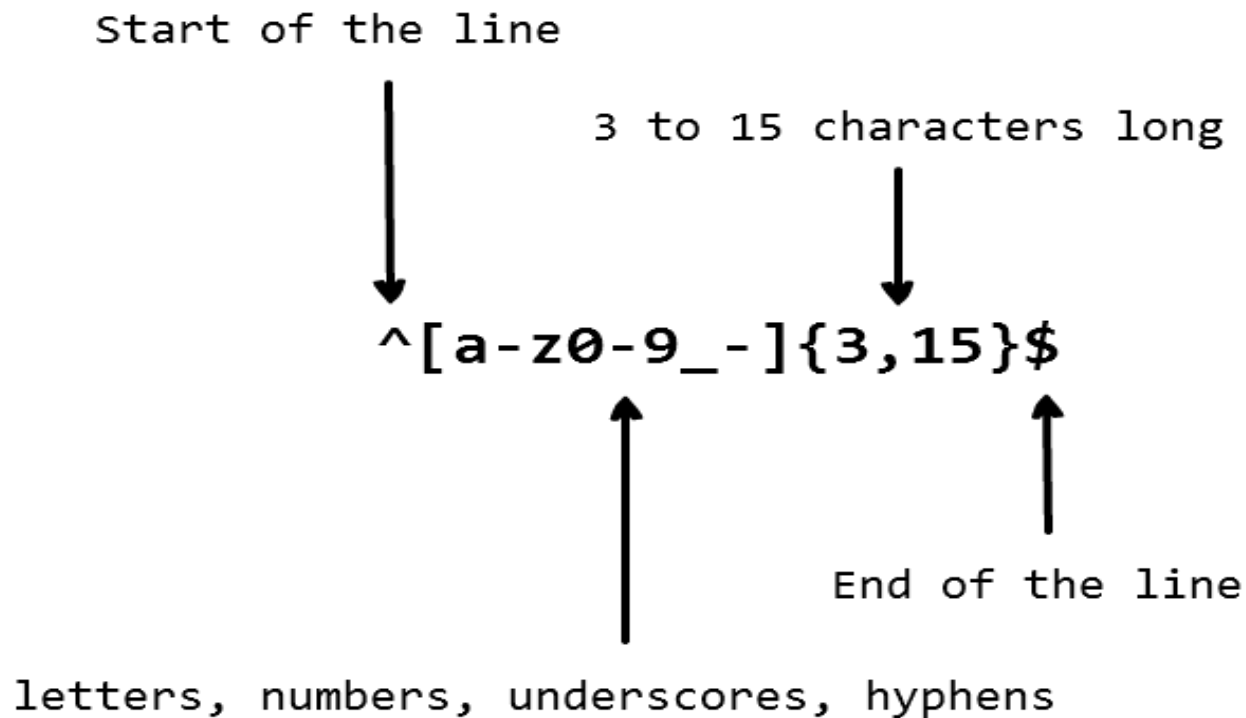
A - မဟာမြတ်မုနိ ဘုရား ၊ မန္တလေး တောင် တို့ ရှိ ပါတယ် ။

Q - ကချင် ပြည်နယ် ရဲ့ မြို့တော် က ဘယ် မြို့ လဲ ။

A - ကချင် ပြည်နယ် ရဲ့ မြို့တော် က မြစ်ကြီးနား မြို့ ဖြစ် ပါ တယ် ။

# Regular Expression (RE)

- **RE** is a special sequence of characters that help **match** or **find** other strings using specialized pattern
- Build **RE** pattern with python **re module**



# Cont'd

- Parallel corpus that we created in the database

Q - မွန်ပြည်နယ် မှာ ဘာ ဘုရား တွေ ရှိ လဲ။

A - မွန်ပြည်နယ် မှာ ကျိုက်ထီးရိုး ဆံတော်ရှင် စေတီ၊ ကျိုက္ခမီ ဘုရား ... တို့ ရှိ ပါတယ် ။

Q - မွန်ပြည်နယ် မှာ ဘာ ကမ်းခြေ တွေ ရှိ လဲ။

A - မွန်ပြည်နယ် မှာ စက်စဲကမ်းခြေ၊ ကဗျာဝကမ်းခြေ ... တို့ ရှိ ပါတယ် ။

- Regular Expression pattern

- r'(.**မွန်ပြည်နယ်**.**ဘုရား**.\*)'

- r'(.**မွန်ပြည်နယ်**.**ကမ်းခြေ**.\*)'

User Input - မွန်ပြည်နယ် မှာ ရှိတဲ့ ဘုရား တွေ ကို သိ ချင် ပါတယ် ။

Chatbot - မွန်ပြည်နယ် မှာ ကျိုက်ထီးရိုး ဆံတော်ရှင် စေတီ၊ ကျိုက္ခမီ ဘုရား ... တို့ ရှိ ပါတယ် ။

User input - မွန်ပြည်နယ် မှာ ရှိတဲ့ ကမ်းခြေ တွေ ကို အလည် သွား ချင် ပါတယ် ။

Chatbot - မွန်ပြည်နယ် မှာ စက်စဲကမ်းခြေ၊ ကဗျာဝကမ်းခြေ ... တို့ ရှိ ပါတယ် ။

# Word Segmentation

- In Myanmar text, spaces are not usually inserted for word boundaries
- Words are composed of single or multiple syllables, not usually separated by white spaces
- **Conditional Random Fields (CRFs)** is used to develop segmentation model
- To segment Myanmar Sentences using CRF Suite
  - Break sentence into **syllable word**
  - Tag each syllable words with **segmentation tags** (labeling)
  - Train the segmentation model using **Conditional Random Fields (CRF suite)**



# Cont'd

Tag number	Tag	Position
1	<	The first syllable/character in a word
2	-	Represents both < and
3		Final syllable/character in a word

Unsegmented input: မွန်ပြည်နယ်ရဲ့မြို့တော်ကမော်လမြိုင်မြို့ဖြစ်ပါတယ်။

Syllable broken sentence: မွန်\_ပြည်\_နယ်\_ရဲ့\_မြို့\_တော်\_က\_မော်\_လ\_မြိုင်\_မြို့\_ဖြစ်\_ပါ\_တယ်\_။

Tag set for CRF Suite: | < | | < | | < - | | | | | |

Segmented output: မွန်\_ပြည်\_နယ်\_ရဲ့\_မြို့\_တော်\_က\_မော်\_လ\_မြိုင်\_မြို့\_ဖြစ်\_ပါ\_တယ်\_။

# POS Tagging (Part of Speech)

- POS tagging is used to extract keywords from the user input and to measure string similarity between user input and existing question in database
- Only keywords (noun, verb, adj, adv) are selected and all other words (part, ppm, conj and etc) are dropped
- The input sentence is tagged with the following POS tag
  - Abbreviation(abb) → အထက (Basic Education High School)
  - Adjective(adj) → ရဲရင့် (brave), လှပ (beautiful)
  - Adverb(adv) → ဖြေးဖြေး (slow), နည်းနည်း (less)
  - Conjunction(conj) → နှင့် (and), သို့မဟုတ် (or)
  - Foreign Word(fw) → 1, 2, 3, Myanmar, BBQ
  - Verb(v) → ကူညီ (help), သွား (go), စား (eat)
  - Noun(n) → ကျောင်း (school), စာအုပ် (book)
  - Number(num) → ၁ (1), ၂ (2), ၃ (3)
  - Particle(part) → များ (plural nouns as “-s”, “-es”), လိမ့် (will)
  - Post-positional Marker(ppm) → သည်, က, ကို, သို့, (at,on,in,to)
  - Pronoun(pron) → ကျွန်တော် (I), ကျွန်မ (I), သင် (You), သူ (He)

# Cont'd

- Unsegmented sentence:

မွန်ပြည်နယ်ရဲ့အထင်ကရဘုရားတွေကိုသိချင်ပါတယ်။

- Segmented sentence:

မွန်\_ပြည်နယ်\_ရဲ့\_အထင်ကရ\_ဘုရား\_တွေ\_ကို\_သိ\_ချင်\_ပါ\_တယ်\_။

- POS tagged sentence:

မွန်/n\_ပြည်နယ်/n\_ရဲ့/ppm\_အထင်ကရ/adj\_ဘုရား/n\_တွေ/part\_ကို/ppm\_သိ/v\_  
ချင်/part\_ပါ/part\_တယ်/ppm

- Keyword for string similarity: မွန်\_ပြည်နယ်\_အထင်ကရ\_ဘုရား\_သိ

# String Similarity

- Compare a set of two strings that how much these two strings be closed
- Use **Damerau-Levenshtein Distance algorithm**
- Find minimum distance between the two strings are with these operations; **deletion, insertion, substitution and transposition**
  - Insertion           eg. cat > cart
  - Deletion           eg. cart > cat
  - Substitution       eg. cart > dart
  - Transposition   eg. water > watre
- **Distance** ('a cat', 'an cat') → 1
- **Distance** ('a cat', 'an act') → 2

# Cont'd

## Parallel corpus

Q - ရေးမြို့ မှာ ဘာ ကမ်းခြေ တွေ ရှိ လဲ။

A - ရေးမြို့ မှာ ကဗျာဝကမ်းခြေ၊ ပင်လယ်ဝကမ်းခြေ တို့ ရှိ ပါတယ်။

Q - ရေးမြို့ မှာ ဘာ ဘုရား တွေ ရှိ လဲ။

A - ရေးမြို့ မှာ လေးမျက်နှာ ဘုရား ကြီး၊ ကျိုက်မင်းပလော့ ဆံတော်ရှင် စေတီ ... တို့ ရှိ ပါတယ်။

## Example of how similar two strings and the extracted keywords from the user input and existing question in database

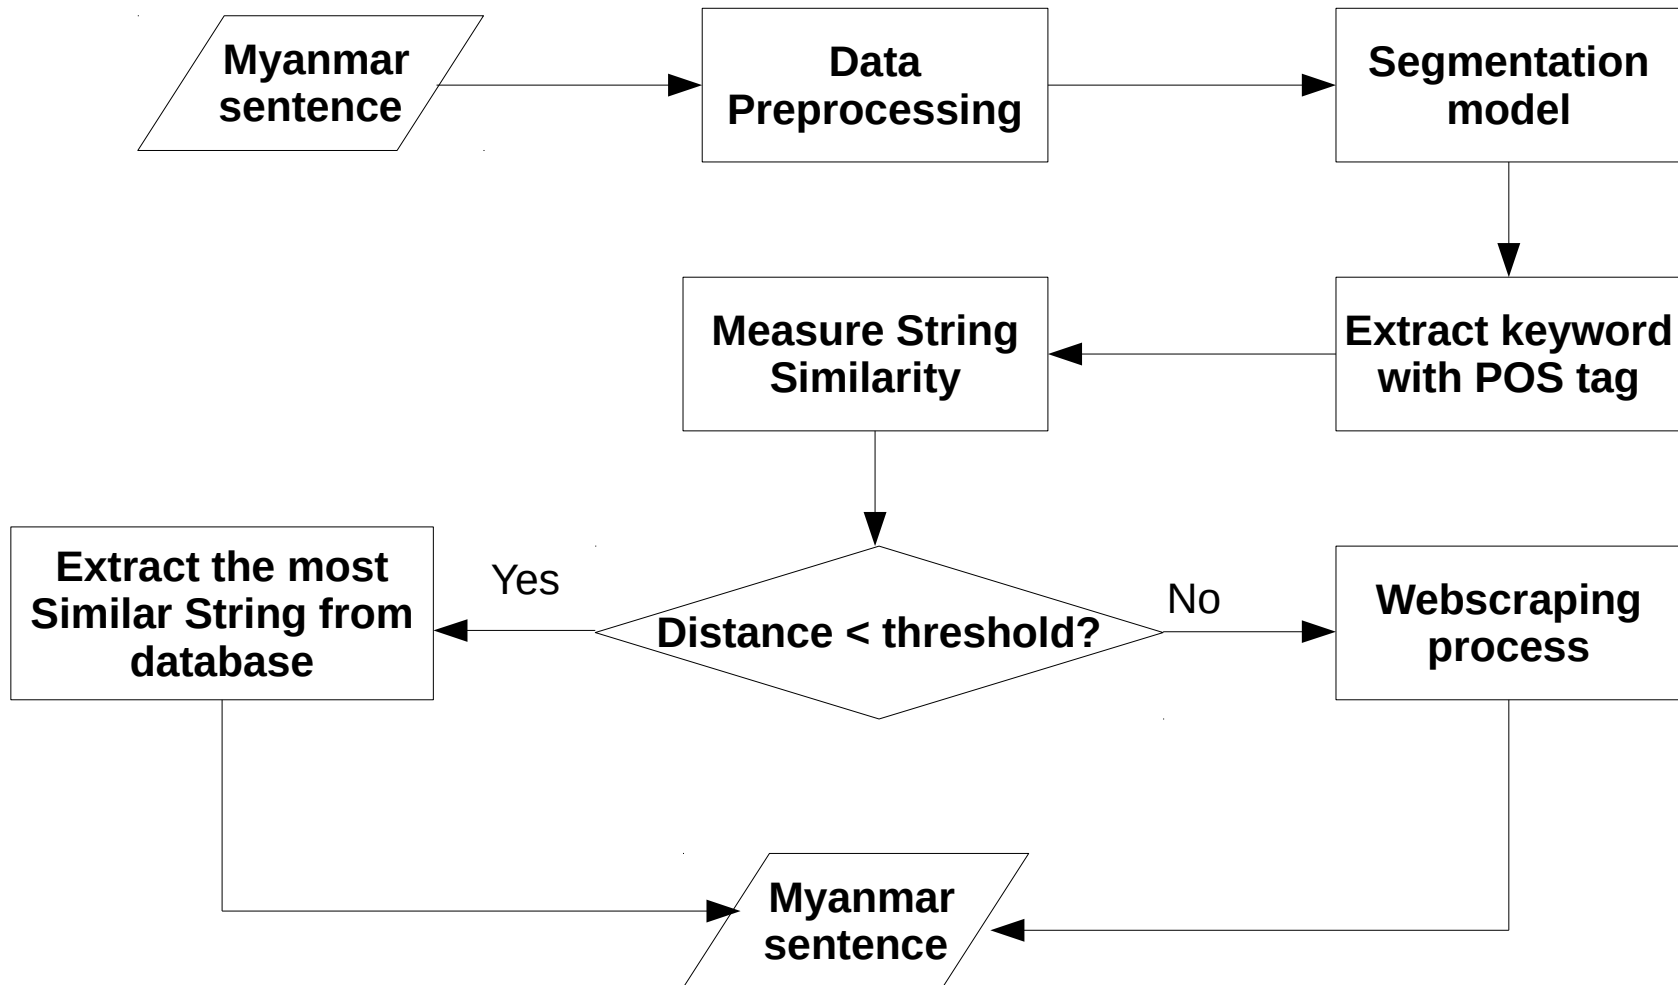
User input – ရေးမြို့ မှာ ကမ်းခြေ တွေ ကို လည် ချင် တယ် ။

**Distance** ("ရေးမြို့\_မှာ\_ဘာ\_ကမ်းခြေ\_တွေ\_ရှိ\_လဲ။" , "ရေးမြို့ \_ကမ်းခြေ\_လည်") → 17

**Distance** ("ရေးမြို့\_မှာ\_ဘာ\_ဘုရား\_တွေ\_ရှိ\_လဲ။" , "ရေးမြို့ \_ကမ်းခြေ\_လည်") → 23

Chatbot Reply - "ရေးမြို့ မှာ ကဗျာဝကမ်းခြေ၊ ပင်လယ်ဝကမ်းခြေ တို့ ရှိ ပါတယ်။"

# System Design



# System Implementation


- Python 3.7.3
- Flask framework

## **Python Library**

- Python **re** module
- BeautifulSoup4
- Urllib2
- request
- google\_images\_download

# Google Map Implementation

- Google map feature is used to search and reply google map when the users ask questions about the **location or direction**
- Regular expression pattern to check if the user asks for the location or direction:
  - `.*လမ်းကြောင်း.*` or `.*လမ်းညွှန်.*`  
or `.*ဘယ်.*မှာ.*`
- User input – ပြင်ဦးလွင် မြို့ ကို **လမ်းညွှန်** ပေး ပါဦး ။





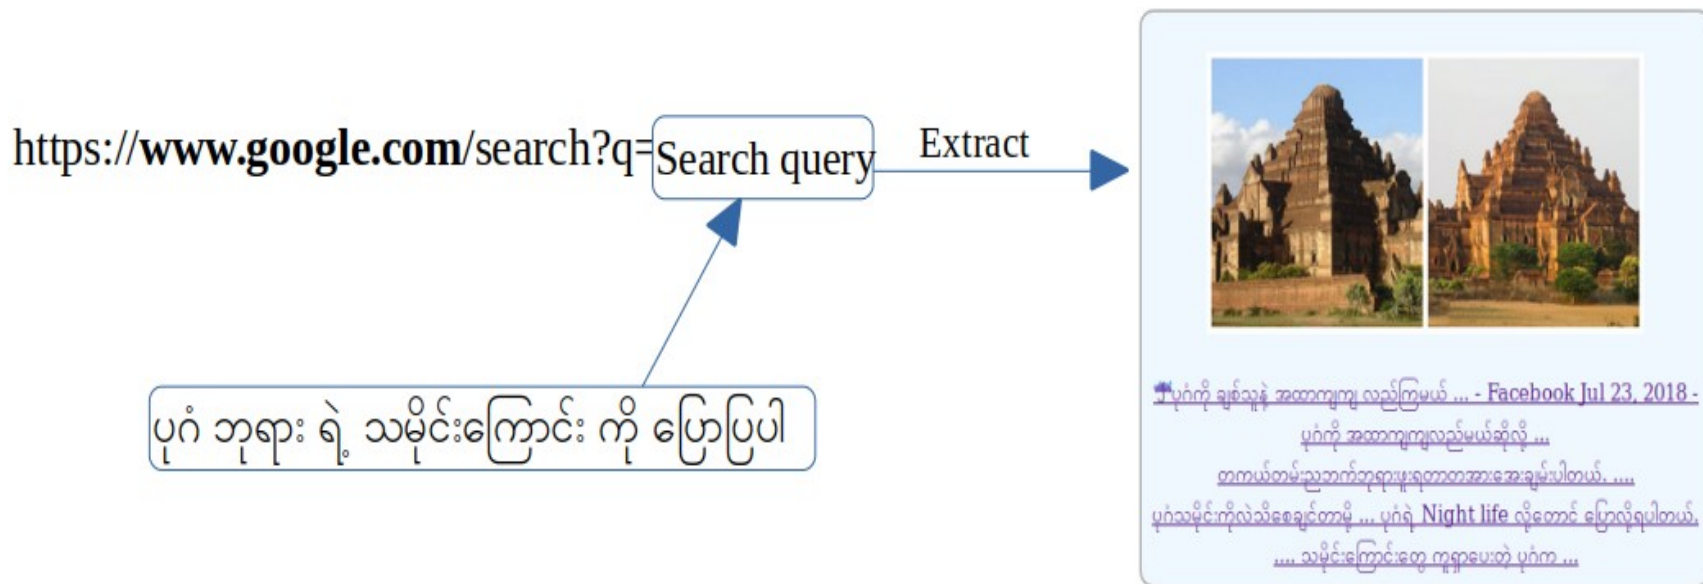
# YouTube Video Implementation

- Chatbot can reply both text message and videos from YouTube that the user can be satisfied.
- BeautifulSoup4 and urllib libraries are used to implement YouTube Videos
- Example of search query -  
Url → "https://www.youtube.com/results?search\_query=" + **query**
- User input –
- Chatbot – Scrape **YouTube video** that is corresponding with the user search input



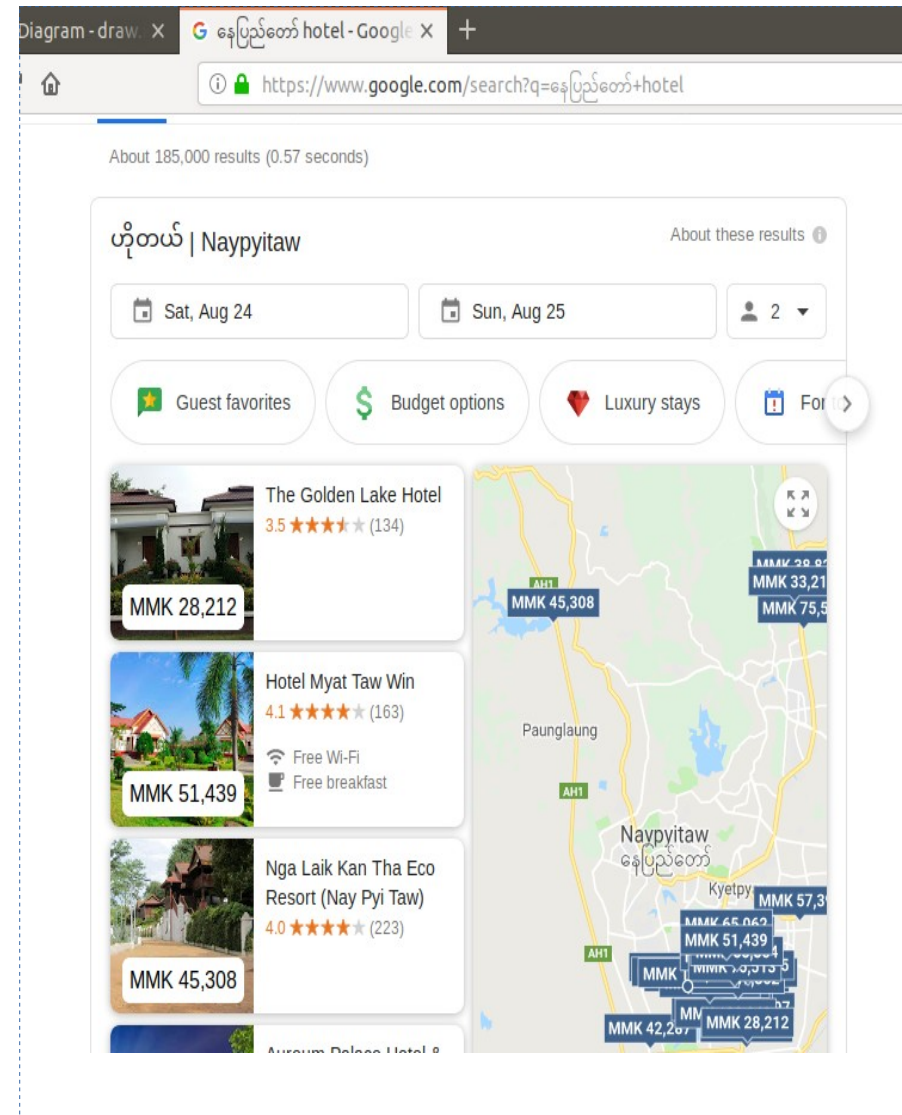
# Web Scraping Link, Image for out of Database State

- Chatbot will also response search results with corresponding website link , description and images about the user input from Google

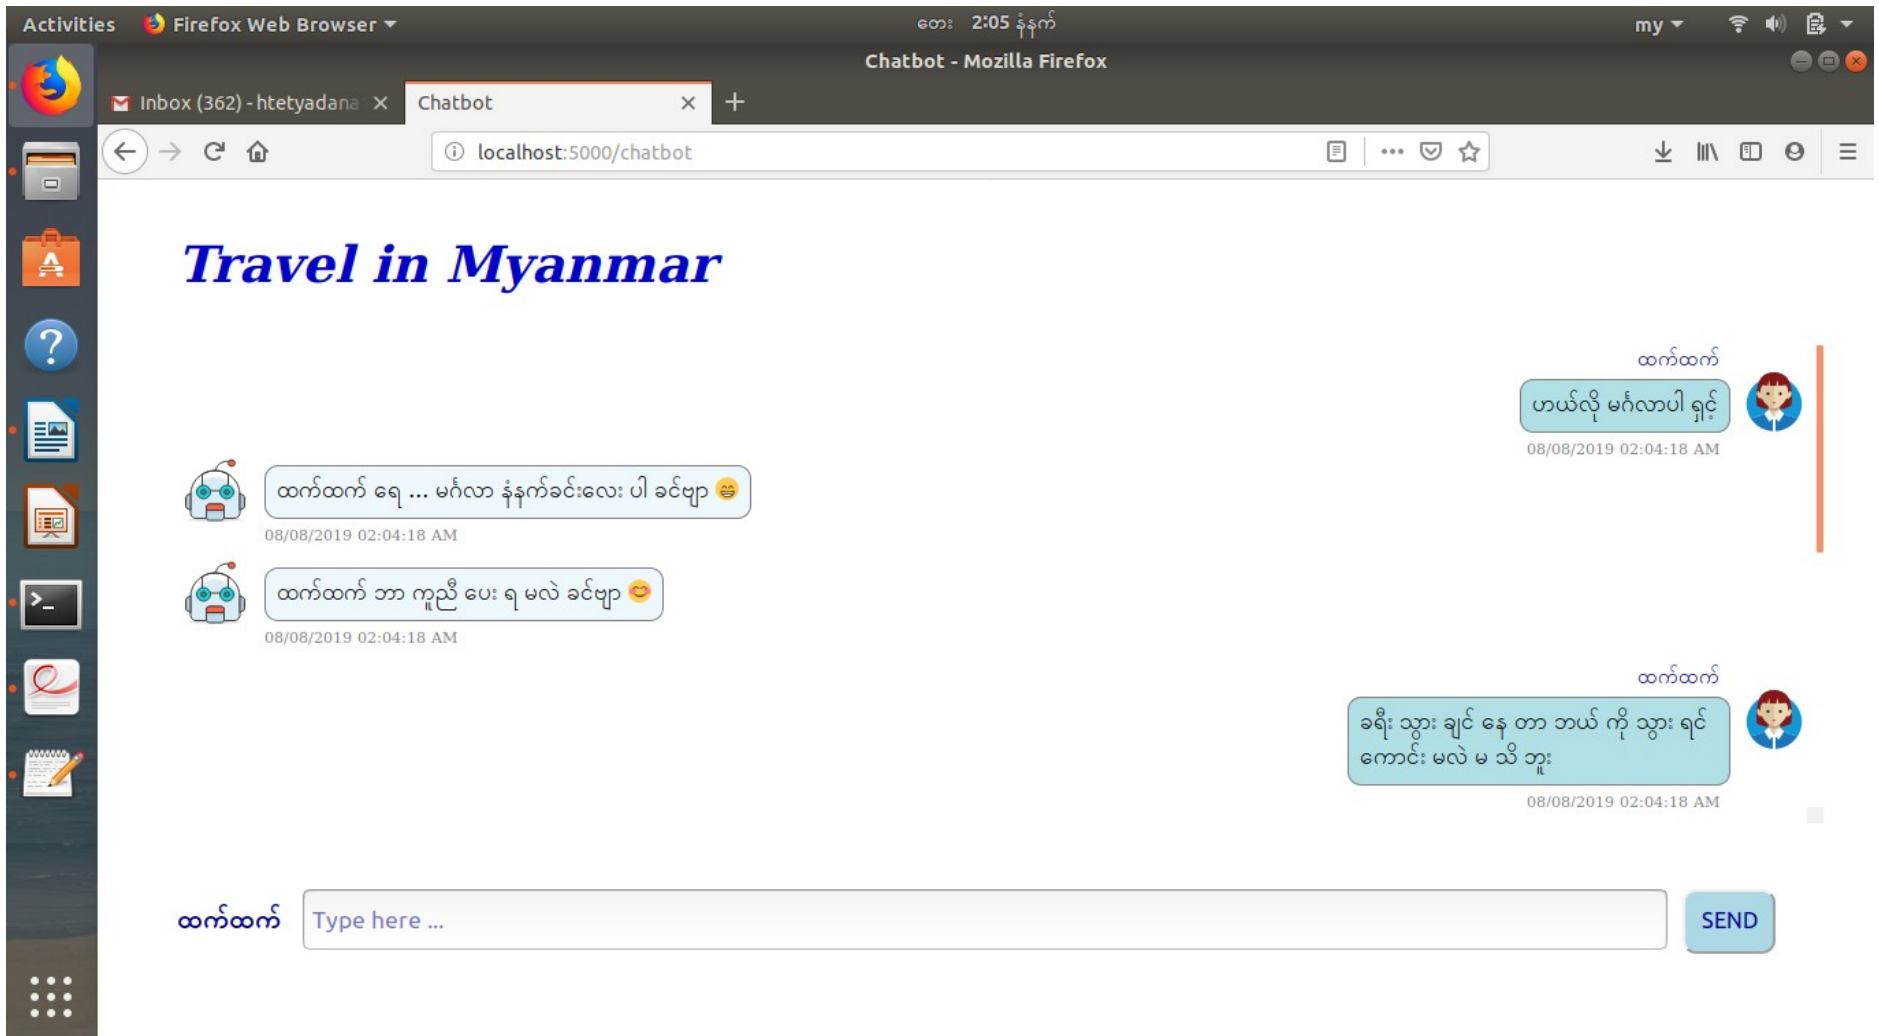


# Scraping Hotel Link

- Chatbot can reply hotel link, description and price of hotel
- Regular Expression pattern to check if the input is to search Hotel
  - ♦ `.*ဟိုတယ်.*`
  - ♦ `.*ဟော်တယ်.*`
  - ♦ `.*တည်းခိုခန်း.*`
  - ♦ `.*hotel.*`
  - ♦ `.*မိုတယ်.*`
- User input – နေပြည်တော် မှာ ဘာ ဟိုတယ် တွေ ရှိ လဲ။
- Url → `https://www.google.com/search`  
`q=နေပြည်တော်+hotel`



# System output



# Evaluation

- A Likert scale is a rating scale that measures how people feel about products, services, or experiences
- Eight user satisfaction survey questions are prepared and each question was defined with satisfaction range 1 to 5
- Ten conversation scenarios are created based on several categories such as pagodas, hotels, beaches, etc
- This system is evaluated with 16 users (13 females and 3 males), the age range is between 22 and 26

# Overall Likert scale evaluation

	User 1	User 2	User 3	User 4	User 5	User 6	User 7	User 8	Overall
Easy to use	5	3	3	4	3	3	4	5	3.75
Easy to understand	3	3	3	2	3	3	3	3	2.88
Fast to reply	3	4	5	4	3	4	3	4	3.75
Satisfied on response	2	3	3	3	2	2	3	3	2.63
Expected response	3	3	3	3	2	2	2	3	2.63
Give help and advice	3	3	2	3	3	3	3	3	2.88
Resonable response	3	2	3	2	3	2	2	3	2.5
Future use	3	3	3	4	4	3	3	4	3.38

# Features and Limitations

## **FEATURES**

- Give informations about pagoda, popular events, famous places, restaurants, markets, hotels, beaches, waterfalls, monastery, weather, transportation
- Reply Google Links, images, YouTube videos, Google map direction when the user input is not in created database

## **LIMITATIONS**

- Only questions about Mon State and Mandalay region can be replied because only data of these two places have been cleaned and structured
- Only Myanmar Language is supported

# Future Extensions

- To prepare and collect more detailed informations about places in Myanmar
- To develop voice recognition between user-chatbot interaction
- To be enable to translate conversation of users and chatbot to English Language to support for the foreigners
- To develop chatbot interface on Messenger platform



Thank You ...

**QUESTIONS?**